Calibre

Simulateur adaptatif d'entraînement à la détection de désinformation et de contenu manipulé

Mini-projet — Durée : 5 jours

1. Description du projet

Calibre est une plateforme qui entraîne des employés à repérer les contenus trompeurs qu'ils reçoivent au quotidien (newsletter, communiqué, rapport interne, message d'information). L'apprenant reçoit dans une boîte mail simulée un contenu généré par LLM, tantôt fiable, tantôt manipulé par une technique précise (statistique déformée, citation inventée, fausse urgence, source douteuse). Il indique si le contenu est fiable ou suspect, désigne la technique repérée et explique son raisonnement. Le système adapte ensuite la difficulté et les techniques proposées à ses résultats. Un tableau de bord permet au manager de suivre un score de maturité par équipe et par technique de manipulation.

2. Problème résolu

Les employés sont exposés chaque jour à des informations fausses ou biaisées, de plus en plus convaincantes grâce à l'IA générative, et peuvent prendre de mauvaises décisions ou relayer ces contenus. Les formations classiques se limitent à des conseils généraux et ne vérifient pas si la personne sait réellement détecter une manipulation. Les entreprises n'ont aucune mesure de la vulnérabilité de leurs équipes. Calibre propose un entraînement pratique, progressif et mesurable, sans risque (contenus fictifs, aucun email réel).

3. Technologies utilisées et justification

— **NestJS** : architecture modulaire (génération, correction, campagnes, xAPI, SCORM) et planificateur de tâches pour l'envoi des emails.
— **React** : interface d'inbox simulée avec outil de surlignage des passages suspects, et tableau de bord (heatmap équipe × technique) pour le manager.
— **LLM avec garde-fous** : génération de contenus fictifs sur des sujets inventés, avec une technique de manipulation étiquetée à l'avance. Sortie JSON validée par schéma, vérification que l'étiquette correspond au contenu généré, filtre de données personnelles et de sujets sensibles, protection contre l'injection de prompt (la réponse de l'apprenant est une donnée non fiable) et contenus de secours en cas d'échec.
— **PostgreSQL** : stockage relationnel des utilisateurs, équipes, contenus, étiquettes et niveaux, et des statements xAPI en JSONB.
— **xAPI et SCORM 1.2** : standards de l'e-learning qui rendent les résultats compatibles avec n'importe quel LMS (traçabilité et export des parcours).
— **Infrastructure email sandbox (Mailpit, Docker)** : envoi et réception d'emails réalistes en environnement isolé.

4. Originalité

— **Génération par technique étiquetée** : chaque contenu manipulé est produit avec une technique connue, ce qui permet de vérifier par le code si l'apprenant a trouvé la bonne ; le LLM n'évalue que l'explication.
— **Contenus fiables parmi les pièges** : une partie des contenus est authentique, afin de mesurer aussi le scepticisme excessif et pas seulement la naïveté.
— **Difficulté de type Elo par technique** : le moteur augmente la subtilité des manipulations et choisit les techniques les plus faibles pour chaque apprenant.
— **Révélation pédagogique** : après la réponse, le contenu est réaffiché avec les passages manipulés surlignés et la technique expliquée.
— **Utilisation de l'IA contre ses abus** : la même IA générative qui produit la désinformation sert à former les personnes à la reconnaître.

5. Résultats attendus

Un prototype fonctionnel, démontrable en moins de 3 minutes : envoi d'un contenu, verdict et explication de l'apprenant, correction avec révélation des passages manipulés, mise à jour de la heatmap d'équipe, génération de statements xAPI et export d'un package SCORM 1.2. Tous les contenus portent sur des sujets fictifs et ne sont pas destinés à être diffusés.